

Procesos espacio-temporales de tipo self-exciting: Extensiones recientes y aplicaciones a datos criminológicos

Álvaro Briz Redón

Departamento de Estadística e Investigación Operativa
Universitat de València

`alvaro.briz@uv.es`

6 de mayo de 2025, Bogotá, D.C.
IV Congreso Colombiano de Estadística



Contenidos

- 1 Preliminares
- 2 Procesos self-exciting
- 3 Nueva propuesta
- 4 Estudio de simulación
- 5 Estudio de caso
- 6 Conclusiones

¿Qué es un proceso puntual?

- Es un proceso estocástico que describe la ocurrencia de puntos (*eventos*) sobre un espacio $W \subset \mathbb{R}^d$.
- Una realización de un proceso puntual es un conjunto de puntos $\{x_i\}_{i=1}^n$, donde $x_i \in W$, el espacio de estudio.
- Cada realización del proceso puntual se denomina *patrón puntual* sobre W .

Proceso puntual de Poisson homogéneo

Empezamos por el proceso puntual más simple: el proceso Poisson homogéneo. Presenta las siguientes características:

- Definido por un único parámetro, que representa que la *función de intensidad* es constante: $\lambda > 0$.
- Propiedades:
 - El número de puntos en una región $A \subset \mathbb{R}^d$ se distribuye según la siguiente distribución de Poisson:

$$N(A) \sim \text{Poisson}(\lambda|A|),$$

donde $|A|$ representa el volumen de A .

- Independencia: Si A_1 y A_2 son regiones disjuntas ($A_1 \cap A_2 = \emptyset$), entonces $N(A_1)$ y $N(A_2)$ son independientes.

Función de intensidad

Hemos dicho que la función de intensidad en el proceso Poisson homogéneo es constante e igual a λ . **¿Qué es exactamente la función de intensidad?**

Sobre un espacio $W \subset \mathbb{R}^d$, la función de intensidad se define como:

$$\lambda(x) = \lim_{|dx| \rightarrow 0} \frac{\mathbb{E}[N(dx)]}{|dx|}, \forall x \in W$$

En palabras, esto significa que el número de puntos esperados en una región infinitesimal alrededor de $x \in W$. Por tanto, si $\lambda(x) = \lambda$:

$$E(N(A)) = \lambda|A|, \forall A \subset W$$

Proceso puntual de Poisson inhomogéneo

En general, es poco realista pensar que la intensidad de un proceso es constante sobre todo el espacio W . El proceso Poisson inhomogéneo mantiene las dos propiedades básicas del Poisson homogéneo, pero ahora:

$$E(N(A)) = \int_A \lambda(x) dx$$

Si asumimos que la intensidad $\lambda(x)$ es paramétrica y dependiente de un vector de parámetros, θ , la función de verosimilitud es (Daley and Vere-Jones, 2002):

$$L(\theta) = \exp \left(- \int_W \lambda(u) du \right) \prod_{i=1}^n \lambda(x_i)$$

Y la de log-verosimilitud:

$$\log L(\theta) = \sum_{i=1}^n \log \lambda(x_i) - \int_W \lambda(u) du$$

Procesos self-exciting: Motivación

- Los procesos puntuales de tipo self-exciting (auto-excitables) son herramientas fundamentales para modelar eventos **recurrentes**.
- Se usan ampliamente en criminología, sismología, economía y epidemiología.
- En estos modelos, se asume que los eventos pasados incrementan la probabilidad de eventos futuros **cercanos en espacio y tiempo**.
- Permiten capturar la **interacción espacio-temporal** del proceso subyacente.

Función de intensidad condicional

- Sea $\{(x_i, t_i)\}_{i=1}^n \subset W \times T \subset \mathbb{R}^2 \times \mathbb{R}$ una realización de un proceso puntual espacio-temporal, donde x_i indica posición espacial y t_i temporal.
- Asumimos que las localizaciones temporales están ordenadas y que no presentan empates: $t_1 < t_2 < \dots < t_n$ (*orderly pattern*).
- La intensidad condicional define la probabilidad instantánea de un nuevo evento dadas las observaciones previas:

$$\lambda(x, t | \mathcal{H}_t) = \lim_{|dx|, |dt| \rightarrow 0} \frac{\mathbb{E}[N(dx \times dt) | \mathcal{H}_t]}{|dx \times dt|},$$

donde $\mathcal{H}_t = \{(x_i, t_i) : t_i < t\}$ representa *la historia del proceso* en tiempo t .

Modelo self-exciting estándar

El modelo self-exciting estándar presenta la siguiente función de intensidad condicional (con sus ligeras variantes):

$$\lambda(x, t | \mathcal{H}_t) = \lambda_0 + \sum_{j: t_j < t} \theta e^{-\frac{|t-t_j|}{\varphi_T}} e^{-\frac{\|x-x_j\|}{\varphi_S}}$$

Descripción de parámetros:

- λ_0 : Parámetro de intensidad de fondo (homogénea). Puede reemplazarse por una intensidad inhomogénea, dependiente de covariables, por ejemplo: $\exp(\beta_1 X_1(x, t) + \dots + \beta_p X_p(x, t))$.
- θ : Parámetro de productividad. Representa la contribución máxima de un evento previo a la intensidad condicional.
- φ_T, φ_S : Parámetros que controlan el nivel de decaída del efecto en el tiempo y el espacio.

Modelo self-exciting estándar: Limitaciones

El modelo self-exciting estándar presenta algunas limitaciones conocidas:

- Se asume que la influencia de cada evento previo en la intensidad es **separable en espacio y tiempo** (el término $\theta e^{-\frac{|t-t_j|}{\varphi_T}} e^{-\frac{\|x-x_j\|}{\varphi_S}}$ es separable en espacio y tiempo).
- Se asume que el **parámetro de productividad, θ , es constante**, no depende ni del evento ni de la localización del evento.
Recientemente, nos hemos centrado en esta cuestión (Briz-Redón and Mateu, 2025).

Modelos self-exciting con productividad variable

Ya existen propuestas sobre modelos self-exciting con productividad variable. Por ejemplo:

- El modelo Epidemic-Type Aftershock Sequence (ETAS) ampliamente utilizado en sismología (Ogata, 1988), asume que la influencia de cada terremoto previamente observado en la intensidad condicional **depende de la magnitud de dicho terremoto**.

En concreto, a partir de la ley de Omori (Utsu et al., 1995), la cual describe cómo decae la intensidad sísmica tras un terremoto previo, se emplea una intensidad (temporal) del tipo:

$$\lambda(t) = \lambda_0 + \sum_{j:t_j < t} \frac{K_0}{(t - t_j + c)^p} e^{\alpha(M_j - M_0)}$$

Modelos self-exciting con productividad variable

Ya existen propuestas sobre modelos self-exciting con productividad variable. Por ejemplo:

- En el ámbito de la criminología, se han propuesto modelos self-exciting con productividad variable **según el tipo de evento delictivo** (considerando patrones marcados). Por tanto, la productividad en este caso toma valores en un conjunto finito (Mohler, 2014; Mohler et al., 2018).
- En el ámbito de la epidemiología, algunos autores han vinculado el parámetro de productividad a **covariables estáticas o variables en el tiempo** para analizar la propagación del COVID-19 (Chiang et al., 2022), mientras que otros han propuesto que el parámetro de productividad está **inversamente relacionado con la intensidad condicional** debida a intervenciones humanas (Schoenberg et al., 2019).

Modelos self-exciting con productividad variable

Ya existen propuestas sobre modelos self-exciting con productividad variable. Por ejemplo:

- Además, se han empleado métodos **no paramétricos** para estimar el parámetro de productividad **en función de las características del evento**, como la magnitud del terremoto en el contexto de los estudios sismológicos (Fox et al., 2016; Marsan and Lengline, 2008; Schoenberg, 2022), o en función del tiempo (Lewis and Mohler, 2011; Phillips and Schoenberg, 2024).
- Más recientemente, Kwon et al. (2023) introdujeron un modelo espacio-temporal flexible de autoexcitación para el análisis de terremotos. Su modelo incluye un término adicional que permite que la productividad varíe en el espacio, estimada de forma **no paramétrica en función de la ubicación espacial del evento**.

Modelos self-exciting con productividad variable

Algunas posibles limitaciones de estas propuestas:

- Requieren **suposiciones fuertes** sobre el parámetro de productividad. Habitualmente, no disponemos de tanta certeza sobre el problema.
- No suelen tener en cuenta la **localización espacial** del evento. En caso de hacerlo, solo encontramos una propuesta no paramétrica (Kwon et al., 2023).
- No tienen en cuenta la localización **tanto en espacio como en tiempo**.

Modelo propuesto con productividad variable

Para tratar de mejorar con respecto de algunas de estas limitaciones, planteamos la siguiente propuesta de modelo self-exciting:

$$\lambda(x, t | \mathcal{H}_t) = \lambda_0 + \sum_{j: t_j < t} b(x)b(t)\theta e^{-\frac{|t-t_j|}{\varphi_T}} e^{-\frac{\|x-x_j\|}{\varphi_S}}$$

En este nuevo modelo tenemos:

- $b(x), b(t) \in [0, 1]$ actúan como *factores de corrección espacial y temporal*, respectivamente.
- Por tanto, el nuevo parámetro de productividad es $b(x)b(t)\theta$, el cual varía en espacio y tiempo.
- Los factores de corrección se definen mediante funciones spline:

$$\text{logit}(b(x)) = \sum_k \alpha_k f_k(x), \quad \text{logit}(b(t)) = \sum_\ell \beta_\ell f_\ell(t)$$

Modelo propuesto con productividad variable

Potenciales ventajas del modelo propuesto:

- Permite considerar que la productividad es **variable en espacio y tiempo** de forma **flexible, sin necesidad** de hacer **suposiciones fuertes** sobre el mecanismo que hace variar la productividad.
- El uso de funciones de tipo spline garantiza que la variación en espacio y tiempo de la productividad sea **suave**. Esto puede facilitar la **identificación** de patrones de variación.

Potenciales desventajas del modelo propuesto:

- Incrementa considerablemente la **complejidad computacional** del modelo.
- Requiere de la **elección de una base de splines**. Si escogemos una base muy densa (con muchas funciones implicadas), el coste computacional podría resultar excesivo.

Inferencia e implementación

- Se realiza inferencia Bayesiana, trabajando con la función de log-verosimilitud asociada a un proceso puntual, donde Θ representa el conjunto de parámetros implicados:

$$\ell(\Theta) = \sum_{i=1}^n \log(\lambda(x_i, t_i | \mathcal{H}_{t_i})) - \int_T \int_W \lambda(x, t | \mathcal{H}_t) dx dt$$

- Se imponen las siguientes distribuciones previas:

$$\begin{aligned}\lambda_0 &\sim \text{Gamma}(10 \frac{n}{|W||T|}, 10) \\ \alpha_k &\sim \text{Normal}(0, 10), \beta_\ell \sim \text{Normal}(0, 10) \\ \theta &\sim \text{Gamma}(\text{mean} = \widehat{\mathbb{E}(\theta_{std})}, \text{sd} = \widehat{\text{SD}(\theta_{std})}) \\ \varphi_T &\sim \text{Gamma}(\text{mean} = \widehat{\mathbb{E}(\varphi_{T_{std}})}, \text{sd} = \widehat{\text{SD}(\varphi_{T_{std}})}) \\ \varphi_S &\sim \text{Gamma}(\text{mean} = \widehat{\mathbb{E}(\varphi_{S_{std}})}, \text{sd} = \widehat{\text{SD}(\varphi_{S_{std}})}),\end{aligned}\tag{1}$$

donde se hacen uso de las estimaciones proporcionadas por el modelo self-exciting estándar para elaborar las previas sobre θ , φ_T y φ_S .

- El modelo se ha implementado en R con el paquete `nimble`, el cual permite realizar inferencia Bayesiana con métodos de tipo Markov chain Monte Carlo (MCMC).
- Se usa el **zeros-ones trick** (Ntzoufras, 2011) para trabajar con la función de log-verosimilitud.
- Requiere definir una cuadrícula espacio-temporal razonablemente fina sobre la que se aproxima la integral implicada en la función de log-verosimilitud.
- En el siguiente repositorio de GitHub puede encontrarse la implementación:

<https://github.com/albrizre/SmoothProdSelfExc>

Estudio de simulación: Objetivos

- Evaluar la capacidad del modelo propuesto para capturar variaciones espacio-temporales en el parámetro de productividad.
- Comparar desempeño frente al modelo estándar.
- Comprobar si el proceso de inferencia es robusto.
- Comprobar si el modelo es consistente entre réplicas.

Configuración del estudio de simulación



- Ventana espacial: $W = [0, 1500] \times [0, 1500]$ m.
- Ventana temporal: $T = [0, 365]$ días.
- Generación de patrones basada en estructura de ramificación (*branching structure*) del proceso self-exciting (Zhuang et al., 2004).
- Se simulan 10 patrones por escenario (no son muchas, pero el modelo es computacionalmente costoso).
- Se ajustan ambos modelos (estándar y propuesto) a cada patrón simulado.
- Se emplea una base de B-splines para la parte temporal y una base de thin-plate splines para la espacial.

Algoritmo de simulación de patrones (resumen)

- 1 Generar eventos de fondo (*parents*) mediante un proceso de Poisson homogéneo con intensidad prefijada, λ_0 .
- 2 Para cada evento, generar un número de descendientes (*offsprings*) con una $Po(\kappa(x, t))$, siguiendo la estructura de ramificación del proceso.
La función $\kappa(x, t)$ representa cómo varía la generación de descendientes en espacio y tiempo.
- 3 Para cada evento, generar las localizaciones (x, t) de los descendientes a través de una Normal bivalente para la dispersión espacial y una exponencial para la temporal.
- 4 Repetir el procedimiento recursivamente con los nuevos eventos generados, hasta que no haya más descendientes.



Escenario 1

- $\kappa_1(x, t) = \frac{x_1 + x_2}{3000} e^{-t/100}$
- Mayor productividad hacia la esquina superior derecha de la ventana
- Disminución progresiva con el tiempo





Escenario 2

- $\kappa_2(x, t) = 0.75 \cdot \mathbf{1}_{[1000, 1500]}(x_2) \cdot \mathbf{1}_{[150, 365]}(t)$
- Productividad localizada únicamente en una zona específica de W y T
- El resto del espacio-tiempo se comporta como un proceso de Poisson homogéneo





Escenario 3

- $\kappa_3(x, t) = e^{-\frac{\|x - (750, 750)\|}{500}} e^{-\frac{|t - 150|}{100}}$
- Máximo de productividad en el centro de la ventana y en $t = 150$
- Decece suavemente en espacio y tiempo




Resultados: Escenario 1




Resultados: Escenario 2

**Spatial correction of the productivity parameter
Scenario 2**




**Temporal correction of the productivity parameter
Scenario 2**




Resultados: Escenario 3

**Spatial correction of the productivity parameter
Scenario 3**



**Temporal correction of the productivity parameter
Scenario 3**



Conclusiones del estudio de simulación

- En general, el modelo propuesto, a través de los términos $b(x)$ y $b(t)$, recupera adecuadamente las variaciones de $\kappa(x, t)$.
- Mejor desempeño en escenarios 1 y 2 que en el 3 (emplear una base de splines más densa podría ayudar a mejorar los resultados).
- En general, la variabilidad de la estimaciones entre réplicas no es excesiva. Hay que tener en cuenta que los patrones simulados no son tan grandes (entre 180 y 350 eventos, aproximadamente).

Estudio de caso: Descripción general de los datos

- **Ventana espacial:** Ciudad de Valencia, España, en sus Distritos 1 a 6 (centro de la ciudad y alrededores)
- **Ventana temporal:** Año 2017
- **Eventos registrados:** 641 robos
- **Fuente:** Llamadas al 112 (número de emergencias)

Área de estudio: Ventana espacial


Esta imagen contiene la zona de Valencia que consideraremos:



Figura: Imagen extraída de *OpenStreetMap*

Área de estudio: Ventana espacial

Trabajaremos sobre la siguiente malla, que denotamos G , la cual contiene 647 celdas de $150 \times 150 \text{ m}^2$ (de área 22500 m^2):






Figura: Patrón espacio-temporal observado

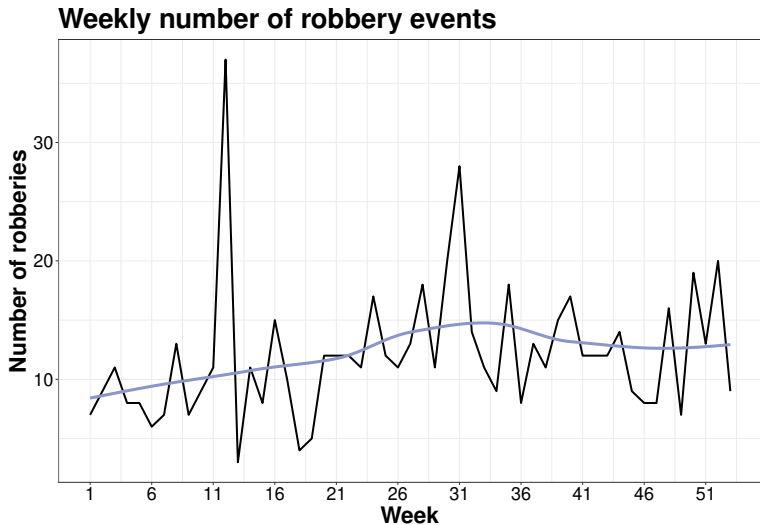
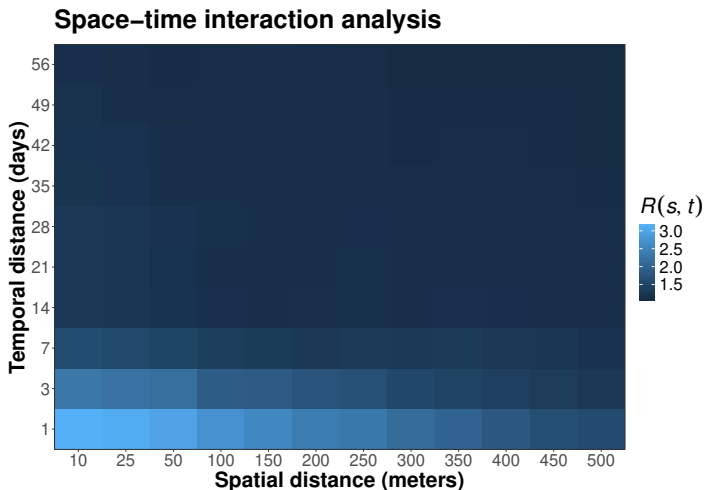


Figura: Número de eventos observados por semana

Interacción espacio-temporal

Se emplea el estadístico $R(s, t) = \frac{K_{ST}(s, t)}{K_S(s)K_T(t)}$, basado en la K -función, para detectar la existencia de interacción espacio-temporal en el patrón.



Estimación de los parámetros compartidos

El análisis exploratorio sugiere que existe interacción espacio-temporal, por lo que tiene sentido ajustar un modelo self-exciting. Pasamos a ver los resultados.

Model	Parameter	Mean	Lower	Upper
Standard	λ_0	$9.32 \cdot 10^{-8}$	$7.83 \cdot 10^{-8}$	$1.11 \cdot 10^{-7}$
	θ	$3.67 \cdot 10^{-7}$	$1.54 \cdot 10^{-7}$	$9.25 \cdot 10^{-7}$
	φ_S	$2.89 \cdot 10^2$	$6.95 \cdot 10^1$	$5.20 \cdot 10^2$
	φ_T	$1.14 \cdot 10^0$	$1.00 \cdot 10^0$	$1.51 \cdot 10^0$
Proposed	λ_0	$7.83 \cdot 10^{-8}$	$6.76 \cdot 10^{-8}$	$8.83 \cdot 10^{-8}$
	θ	$7.60 \cdot 10^{-7}$	$4.59 \cdot 10^{-7}$	$1.17 \cdot 10^{-6}$
	φ_S	$8.32 \cdot 10^2$	$5.95 \cdot 10^2$	$1.13 \cdot 10^3$
	φ_T	$1.12 \cdot 10^0$	$8.96 \cdot 10^{-1}$	$1.37 \cdot 10^0$

Cuadro: Media a posteriori e intervalo de credibilidad al 95 % para los parámetros compartidos por los dos modelos




Figura: Estimación del factor $b(x)$ sobre el área de estudio

Estimación de $b(x)$: *Exceedance probabilities*

Exceedance probability for the spatial correction

$c = 0.5$

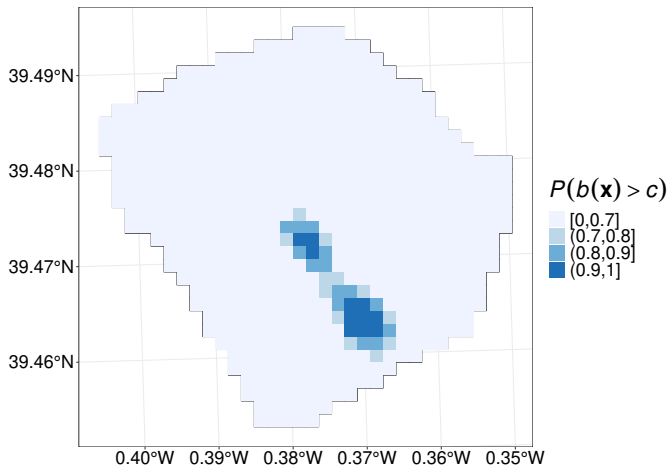


Figura: Exceedance probability calculada como $P(b(x) > 0.5)$




Figura: Estimación del factor $b(t)$ sobre el área de estudio

Estimación de $b(t)$: *Exceedance probabilities*

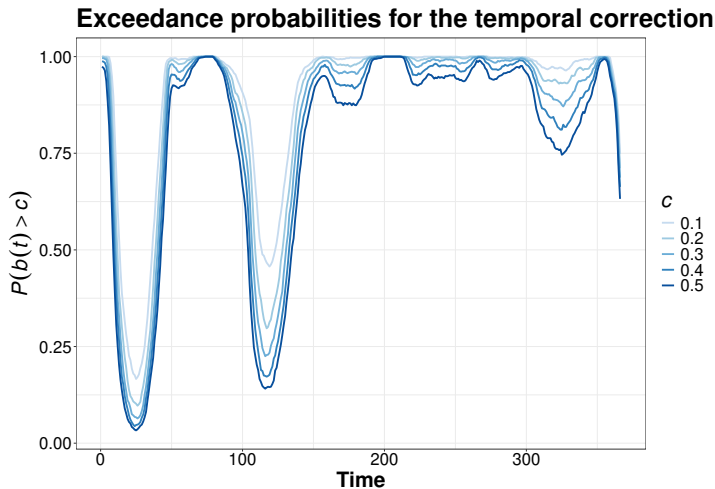



Figura: Exceedance probability calculada como $P(b(t) > c)$, para diversos valores de c

Análisis residual temporal


Se comprueba si los siguientes tiempos transformados se corresponden con un proceso Poisson unitario ($\lambda(t) = 1$):

$$t_i \rightarrow \tau_i = \int_0^{t_i} \int_W \hat{\lambda}_\Theta(x, t | \mathcal{H}_t) dx dt$$

Temporal residual analysis for the standard model



Temporal residual analysis for the proposed model




Análisis residual espacial

Propuesta de Baddeley et al. (2005) como residuo de un proceso puntual espacial:


$$SR_{\hat{\theta}}(c) = \lambda^*(c) - \lambda^\dagger(c)$$

donde $\lambda^*(c)$ es una estimación no paramétrica de la función de intensidad, y $\lambda^\dagger(c)$ una versión suavizada del número estimado de evento en c , de acuerdo con el modelo ajustado.

Spatial residual analysis for the standard model



Spatial residual analysis for the proposed model



Futura extensión: Introducción del concepto de *fairness*

- En aplicaciones **sensibles** (como la criminalidad), los modelos pueden amplificar sesgos espaciales o socioeconómicos preexistentes.
- Puede suceder que sobreestimemos la función de intensidad en localizaciones donde ciertas características poblacionales son más prevalentes.
- El concepto de *fairness* lleva tiempo estudiándose en diversas aplicaciones, incluyendo la criminología (Wu et al., 2023), con el objetivo de garantizar que no existan grupos poblacionales “perjudicados”.
- Podemos tratar de controlar el nivel de *fairness* mediante la inclusión de variables sociodemográficas potencialmente susceptibles de ser perjudicadas y **regularizar** el efecto asociado a estas covariables (con métodos de tipo Lasso).

- El modelo propuesto permite capturar heterogeneidad espacio-temporal en la productividad.
- Aporta interpretabilidad e identifica zonas y periodos con patrones repetitivos.
- El modelo es computacionalmente costoso, por lo que cualquier mejora en este sentido sería beneficiosa.
- El modelo podría extenderse para tener en cuenta el *fairness*.
- Queda también por estudiar el posible problema de identificación entre la tasa de fondo y el parámetro de productividad.

- Baddeley, A., Turner, R., Møller, J., and Hazelton, M. (2005). Residual analysis for spatial point processes (with discussion). *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(5):617–666.
- Briz-Redón, Á. and Mateu, J. (2025). A self-exciting spatio-temporal model with a smooth space-time varying productivity parameter. Submitted for publication.
- Chiang, W.-H., Liu, X., and Mohler, G. (2022). Hawkes process modeling of COVID-19 with mobility leading indicators and spatial covariates. *International Journal of Forecasting*, 38(2):505–520.
- Daley, D. J. and Vere-Jones, D. (2002). *An Introduction to the Theory of Point Processes. Volume I: Elementary Theory and Methods*. Springer New York.

- Fox, E. W., Schoenberg, F. P., and Gordon, J. S. (2016). Spatially inhomogeneous background rate estimators and uncertainty quantification for nonparametric Hawkes point process models of earthquake occurrences. *The Annals of Applied Statistics*, pages 1725–1756.
- Kwon, J., Zheng, Y., and Jun, M. (2023). Flexible spatio-temporal Hawkes process models for earthquake occurrences. *Spatial Statistics*, 54:100728.
- Lewis, E. and Mohler, G. (2011). A nonparametric EM algorithm for multiscale Hawkes processes. *Journal of Nonparametric Statistics*, 1(1):1–20.
- Marsan, D. and Lengline, O. (2008). Extending earthquakes' reach through cascading. *Science*, 319(5866):1076–1079.

Bibliografía III

- Mohler, G. (2014). Marked point process hotspot maps for homicide and gun crime prediction in Chicago. *International Journal of Forecasting*, 30(3):491–497.
- Mohler, G., Carter, J., and Raje, R. (2018). Improving social harm indices with a modulated Hawkes process. *International Journal of Forecasting*, 34(3):431–439.
- Ntzoufras, I. (2011). *Bayesian modeling using WinBUGS*. John Wiley & Sons.
- Ogata, Y. (1988). Statistical models for earthquake occurrences and residual analysis for point processes. *Journal of the American Statistical Association*, 83(401):9–27.
- Phillips, S. and Schoenberg, F. (2024). Efficient non-parametric estimation of variable productivity Hawkes processes. *Journal of Applied Statistics*, pages 1–18.

Bibliografía IV

- Schoenberg, F. P. (2022). Nonparametric estimation of variable productivity Hawkes processes. *Environmetrics*, 33(6):e2747.
- Schoenberg, F. P., Hoffmann, M., and Harrigan, R. J. (2019). A recursive point process model for infectious diseases. *Annals of the Institute of Statistical Mathematics*, 71:1271–1287.
- Utsu, T., Ogata, Y., et al. (1995). The centenary of the Omori formula for a decay law of aftershock activity. *Journal of Physics of the Earth*, 43(1):1–33.
- Wu, J., Abrar, S. M., Awasthi, N., and Frías-Martínez, V. (2023). Auditing the fairness of place-based crime prediction models implemented with deep learning approaches. *Computers, Environment and Urban Systems*, 102:101967.
- Zhuang, J., Ogata, Y., and Vere-Jones, D. (2004). Analyzing earthquake clustering features by using stochastic reconstruction. *Journal of Geophysical Research: Solid Earth*, 109(B5).

¡Muchas gracias por vuestra
atención!